РЕЗУЛЬТАТЫ РАЗВЕДОЧНОГО АНАЛИЗА ДАННЫХ

Каждый участник команды собирал независимую часть датасета по заранее оговоренным классам. На данном этапе собранные изображения объединены в единый датасет для дальнейшего обучения моделей.

В датасете выделено 156 классов и 50800 размеченных изображений продуктов. Суммарный вес набора данных составляет примерно 10 ГБ. Для сбора применялись различные подходы: от скачивания размеченных изображений из крупнейших библиотек до поиска фотографий с помощью LLM.

Разведочный анализ позволил оценить соответствие изображений своим меткам классов, а также исследовать различия в ширине, высоте, формате и яркости изображений. Распределение изображений по классам оказалось сильно несбалансированным: у баранины, говядины и курицы по несколько тысяч изображений, в то время как некоторые классы представлены всего несколькими фотографиями. Например, для нектарина удалось найти только два изображения. Такой дисбаланс связан с различиями в подходах к сбору данных среди участников, а также с редкостью и относительной непопулярностью отдельных продуктов питания. Часть непопулярных классов будет удалена из датасета, планируется дополнить оставшиеся маленькие классы новыми изображениями. Рассмотрена возможность аугментации изображений на основе поворота, отражения и понижения яркости.

Для дополнительной валидации качества изображений применялась LLM, которая по заданному промпту определяла, насколько изображение «пригодно» для подачи в модель. Непригодные изображения дополнительно просматривались вручную. Таким образом, в финальном наборе осталось 43000 изображений. В будущем планируется просмотр всех изображений в датасете.

ПРАКТИЧЕСКАЯ ПРИМЕНИМОСТЬ ПРОЕКТА

Проект разрабатывается для людей, которые ведут дневник питания. Ручной поиск продукта и внесение записи после каждого приема пищи может занимать время. По фотографии класс продукта определяется автоматически. Бот рассчитывает калорийность по справочнику и сохраняет запись. Перед сохранением записи пользователь проверяет предложенный продукт и вводит массу.

К трудностям проекта относится отсутствие полноценного датасета для решения поставленной задачи. Данные приходится собирать самостоятельно из самых разных источников. Какие-то продукты могут быть непопулярны или недоступны в том или ином регионе, а достать такие изображения в открытом доступе не так просто. Обучить модель распознавать непопулярный класс становится непростой задачей. Определять массу по фотографии с высокой долей точности практически не представляется возможным – изображения могут быть представлены в разных масштабах. Расчет КБЖУ для составных блюд крайне проблематичен, так как состав блюда не всегда прозрачен и хорошо читается на фотографии, модель может сильно ошибаться в своем прогнозе.

Для оценки качества продукта планируется проведение тестирования с привлечением независимых пользователей. Для классификатора будут оценены метрики macro-F1, recall, матрицы ошибок. Для сервиса дополнительно будет рассчитана доля исправлений пользователем, доля успешных записей, время внесения и качество отказа на неизвестной или смешанной еде.